



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



**TFG del Grado en Ingeniería
Informática**

**Identificación de Parkinson
mediante visión artificial**



Presentado por Álvaro Alonso Marín
en Universidad de Burgos — 24 de abril
de 2022

Tutores: Álgvar Arnaiz González y Alicia
Olivares Gil



UNIVERSIDAD DE BURGOS
ESCUELA POLITÉCNICA SUPERIOR
Grado en Ingeniería Informática



D. nombre tutor, profesor del departamento de nombre departamento, área de nombre área.

Expone:

Que el alumno D. Álvaro Alonso Marín, con DNI 71307942F, ha realizado el Trabajo final de Grado en Ingeniería Informática titulado Identificación de Parkinson mediante visión artificial.

Y que dicho trabajo ha sido realizado por el alumno bajo la dirección del que suscribe, en virtud de lo cual se autoriza su presentación y defensa.

En Burgos, 24 de abril de 2022

Vº. Bº. del Tutor:

Vº. Bº. del co-tutor:

Dña. Alicia Olivares Gil

D. Álgar Arnaiz González

Resumen

Descriptores

Abstract

Keywords

Índice general

Índice general	iii
Índice de figuras	iv
Índice de tablas	v
Introducción	1
1.1. Estructura de la memoria	1
1.2. Estructura de los apéndices	2
Objetivos del proyecto	3
Conceptos teóricos	5
3.1. Procesamiento de vídeo	5
3.2. Limpieza de los datos	7
3.3. Minería de datos	8
3.4. Evaluación de los resultados	11
Técnicas y herramientas	15
4.1. Herramientas de desarrollo	15
4.2. Bibliotecas	15
Aspectos relevantes del desarrollo del proyecto	17
5.1. Limpieza de datos	17
5.2. Obtención de características	18
Trabajos relacionados	21

Conclusiones y Líneas de trabajo futuras	33
Bibliografía	35

Índice de figuras

3.1. Puntos de la mano y su nombre.	6
3.2. Representación gráfica de los datos obtenidos en uno de los vídeos con y sin filtrado.	7
3.3. Ampliación de uno de los picos donde se aprecia la curva con y sin suavizado.	8
3.4. Validación cruzada dividiendo el conjunto de ejemplos en 4 partes.	10
3.5. Tres tipos de curvas ROC.	14
6.1. Prueba a papel que realizó una persona con Parkinson en este proyecto y la hoja en blanco de la prueba.	22
6.2. Resultado obtenido en cada dibujo de los ejercicios c y d.	23
6.3. Mano con los dedos índice y pulgar etiquetados.	25
6.4. Detección realizada con un ajuste ideal.	25
6.5. Gráficas donde se visualiza la obtención de la velocidad, de la amplitud y del ritmo.	27
6.6. Pasos que se siguieron para la realización de este proyecto.	29
6.7. Detección de la silueta de cada mano, orientación del movimiento, posiciones del los dedos índice y la imagen actual.	29
6.8. Marcadores rojos y comparación del algoritmo y el procesado de los marcadores.	30

Índice de tablas

6.1. Tabla que resume las medidas utilizadas para detectar el Parkinson.	31
--	----

Introducción

El Parkinson [14] es una enfermedad neurodegenerativa crónica, la cual tiene síntomas como el aumento del tono muscular [12] (contracción parcial, pasiva y continua de los músculos) y temblores.

Destaca como trastorno de movimiento, aunque también afecta a la función cognitiva, a la aparición de depresión y dolores, y a la función del sistema nervioso autónomo [17] (sistema nervioso que controla las funciones involuntarias de las vísceras, como la frecuencia cardíaca o la digestión).

El Parkinson es la segunda enfermedad neurodegenerativa más frecuente, ya que la primera es el Alzheimer. Es más propenso a aparecer en personas mayores de 60 años, sin embargo, podrían comenzar los síntomas desde los 40 años y que la incidencia vaya incrementándose con el paso de los años, aunque, generalmente, esto es más propenso en los hombres.

Es una enfermedad que empeora con el tiempo debido a la destrucción progresiva de las neuronas que están pigmentadas de la sustancia negra [11] (ubicadas en una parte del encéfalo), que afecta al sistema nervioso central.

Por ello, un proyecto enfocado a facilitar su identificación puede ayudar al equipo médico encargado y a los pacientes, y con ello, realizar el tratamiento correspondiente cuanto antes para disminuir los daños.

1.1. Estructura de la memoria

La memoria está compuesta por los siguientes apartados:

- **Introducción:** se realiza una breve descripción del cometido del proyecto.

- **Objetivos del proyecto:** se exponen los objetivos que tiene este proyecto.
- **Conceptos teóricos:** se exponen aquellos conceptos importantes para comprender cómo se ha realizado este proyecto.
- **Técnicas y herramientas:** se indican aquellas técnicas y herramientas que han sido utilizadas para el desarrollo del proyecto.
- **Aspectos relevantes del desarrollo del proyecto:** se exponen aquellos aspectos importantes que han sucedido a lo largo del proyecto.
- **Trabajos relacionados:** se exponen otros trabajos existentes que guardan relación con este proyecto.
- **Conclusiones y líneas de trabajo futuras:**

1.2. Estructura de los apéndices

Los apéndices están compuestos por los siguientes apartados:

- **Plan de Proyecto Software:** se expone la metodología de trabajo utilizada para desarrollar el proyecto.
- **Especificación de Requisitos:**
- **Especificación de Diseño:**
- **Documentación técnica de programación:**

Objetivos del proyecto

En este apartado se van a exponer los objetivos más importantes de este proyecto.

Investigar sobre el aprendizaje automático

Este objetivo es la base del trabajo, ya que, utilizando la inteligencia artificial se pueden conseguir avances en múltiples áreas, entre ellas, la medicina como es en este caso. La inteligencia artificial puede ayudar a los profesionales a realizar sus tareas, e incluso puede servir de apoyo para aquellos que no lo son.

Aunque todavía queda mucho por saber, las técnicas que se conocen en la actualidad pueden ser explotadas para facilitar la vida de las personas. En este proyecto, se utiliza la visión artificial, que es una de las ramas más importantes de la inteligencia artificial. Por ello, este trabajo está motivado por la investigación de cómo podría una máquina aprender de los expertos, sin sustituirles, siendo una ayudante.

Para conseguir este objetivo, es necesario haber investigado en los campos de la minería de datos y de sistemas inteligentes, para extraer características con las que enseñar a la máquina y para hacerle aprender. Dado que se conoce que una persona que padece Parkinson tiene dificultades a la hora de mover sus manos, se pueden extraer características y compararlas con aquellas personas sanas para poder diferenciar a los que tienen la enfermedad de los que no.

Existen varios proyectos que también buscan este mismo objetivo, pero cada uno utiliza técnicas diferentes. Por esta razón, en este proyecto se pretende innovar y buscar otra solución para poder detectar el Parkinson,

ofreciendo a los pacientes y a los expertos otra posibilidad de facilitar el trabajo.

Diseñar e implementar una aplicación web para detectar el Parkinson

Como se ha detallado al comienzo del documento, el Parkinson es una enfermedad muy común, por lo que una aplicación enfocada a facilitar su identificación puede ayudar al equipo médico encargado y a los pacientes, de forma que se pueda realizar el tratamiento correspondiente cuanto antes para disminuir los daños.

Este objetivo trata de crear una aplicación que, dado un vídeo de una mano realizando movimiento de pinza (con los dedos índice y pulgar), consiga detectar si ese usuario tiene Parkinson o no.

Para ello, la aplicación medirá la distancia máxima cada vez que la pinza se abra (las distancias más lejanas entre ambos dedos), además de la velocidad con la que la pinza se abre y se cierra, y obtendrá unos estadísticos, los cuales serán los que identifiquen si es una persona con la enfermedad.

Esto se hará utilizando una biblioteca de visión artificial basada en redes neuronales convolucionales, la cual detecta el esqueleto humano. Dado que en este proyecto se trata con vídeos, la biblioteca detectará los puntos del esqueleto de cada fotograma del vídeo, que habrá que procesarlo para obtener los datos en ese instante de tiempo. De los puntos detectados, el punto del dedo índice y el punto del dedo pulgar serán los que se utilicen para detectar cómo la pinza se abre y se cierra.

Los datos obtenidos gracias a esta biblioteca serán procesados, filtrados y utilizados para entrenar modelos de inteligencia artificial. Sobre estos modelos, se construirá un software con el cual, tras obtener un vídeo, se podrá conocer si la persona del vídeo es una persona con Parkinson o no.

Esta manera de detección se puede utilizar ya que se conoce que una persona con Parkinson abre y cierra la pinza más despacio y con menos amplitud que una persona sin Parkinson.

Conceptos teóricos

En este apartado, se van a exponer aquellos conceptos que requieran ser conocidos para comprender cómo se ha realizado el TFG.

3.1. Procesamiento de vídeo

Dado que este proyecto se fundamenta en obtener datos a partir de vídeos, es necesario conocer algunos conceptos básicos de procesamiento de vídeo.

Vídeos

Para que los vídeos sean procesados, es necesario que exista un proceso de lectura de los fotogramas. Además, en ocasiones se desea que los fotogramas sean guardados con el procesado realizado. Esto es lo que se conoce como objetos de vídeo. Un objeto de vídeo puede ser de lectura, cuando se pretende leer los fotogramas del vídeo, o de escritura, cuando se pretende guardar imágenes en forma de vídeo.

Leer un vídeo no requiere un mayor conocimiento más allá de conocer el concepto de fotograma, pero a la hora de escribir un vídeo es necesario conocer el concepto de codificación. Cuando se desea guardar un vídeo o una colección de fotogramas, se puede codificar en varios tipos, lo cual afectará al tipo de extensión del vídeo. Los codificadores más comunes son: MPEG, H.264, MJPEG, Sorenson, WMV, Ogg Theora, DivX y XviD.

Dependiendo del uso que se le vaya a dar al vídeo, conviene utilizar una codificación u otra, dando lugar a extensiones de vídeo diferentes. Estas

extensiones definen el tipo de formato del vídeo. Los más comunes son: AVI, MOV, MP4, ASF, OGG, FLV, MKV y VOB.

Los vídeos están formados por varias imágenes consecutivas capturadas y reproducidas a cierta velocidad. Esta velocidad se mide en FPS (fotogramas por segundo). Normalmente, los vídeos se capturan a una velocidad de 30 fps y la velocidad de reproducción suele ser la misma, dado que en caso de que una fuese superior a la otra el vídeo se vería acelerado o decelerado.

En ocasiones, podría resultar interesante acelerar o decelerar una colección de fotogramas procesados, por lo que resulta importante tener en cuenta cuánta aceleración tendrá el objeto de vídeo resultante. Esta aceleración se calcula utilizando la siguiente fórmula:

$$\text{aceleración} = \frac{\text{fps}_{\text{reproducción}}}{\text{fps}_{\text{captura}}} \quad (3.1)$$

Puntos de la mano

Una vez comprendidos los conceptos a la hora de procesar vídeos, viene el paso para obtener los puntos de la mano con los que extraer datos que sirvan para realizar una clasificación.

Mediante el objeto de lectura, se van extrayendo todos los fotogramas para procesarlos uno a uno. En cada fotograma, se dibujarán los puntos unidos mediante líneas, tal y como se aprecia en la figura 3.1. Sin embargo, en este trabajo, sólo serán importantes dos de ellos: el 4 y el 8, ya que son los que representan las puntas de los dedos pulgar e índice respectivamente.




Figura 3.1: Puntos de la mano y su nombre [4].

Una vez establecidos los puntos, se van a obtener las coordenadas de cada fotograma donde están ambos puntos, con el fin de obtener la distancia que los separa en cada instante.

3.2. Limpieza de los datos

Dado que la obtención de los datos del paso anterior no es perfecta, hay que utilizar alguna técnica para eliminar el posible ruido que la biblioteca ha podido ocasionar. Este ruido viene dado porque entre fotogramas, la biblioteca puede detectar el dedo en lugares diferentes sin que este se haya movido, provocando que la amplitud de la pinza se vea afectada.

Filtro de Savitzky–Golay

Este filtrado [7] ha sido utilizado para eliminar algunas imperfecciones de los datos. Se basa en el cálculo de una regresión polinomial local de grado k con al menos $k + 1$ puntos equiespaciados que determinan el valor de un nuevo punto. Esto hará que los datos varíen y se suavice la gráfica.

Al dibujar los datos en forma de gráfica, como se observa en la figura 3.2, se puede apreciar cómo algunas zonas no establecen un único máximo o el máximo podría estar exagerado, por lo que es necesario suavizar esos picos para obtener un solo máximo.




Figura 3.2: Representación gráfica de los datos obtenidos en uno de los vídeos sin filtrado (azul) y con filtrado (naranja).

La figura 3.3 muestra uno de los picos de forma ampliada, notándose el suavizado del filtro frente a la gráfica sin suavizar eliminando los picos que producen ruido. Lo ideal sería que la curva fuese lo más perfecta posible, pero el propio pulso de la mano y, sobre todo, la biblioteca que coloca los puntos sobre la mano provocan esas imperfecciones que conviene solucionar. No obstante, aun aplicando el filtrado, no se consigue el resultado ideal, pues el filtrado es únicamente aproximación y una mejora del resultado real.




Figura 3.3: Ampliación de uno de los picos donde se aprecia la curva sin suavizar (azul) de la suavizada con el filtro (naranja).

3.3. Minería de datos

Este punto trata de encontrar patrones en los datos que sirvan para clasificar. Para el problema planteado de predicción, hay que utilizar la clasificación.

La clasificación es una tarea de la minería de datos que realiza un proceso de asignación de una clase u otra dependiendo de los valores que tengan los datos. Extrapolado a este trabajo, esto sería asignar si una persona tiene Parkinson o no dependiendo de las características obtenidas en el punto anterior.

Conjunto de ejemplos

Las características obtenidas son las que conforman el conjunto de datos. Este conjunto de datos será mejor cuantos más ejemplos haya, ya que más opciones podrán abarcar los clasificadores y mejores serán las predicciones.

Los clasificadores se utilizan realizando una separación del conjunto total de los datos. Esta separación da lugar a los datos de entrenamiento y los datos de test:

- Conjunto de entrenamiento: constituye la mayor parte de los datos, entre el 70 % y 80 % generalmente. Sirve para enseñar al modelo a clasificar el conjunto de datos, indicándole qué casos son de una clase y que casos de otra.
- Conjunto de test: Sirve para probar cuánto de bueno es el modelo entrenado con los ejemplos de entrenamiento. Tras las predicciones, se comprobará la clase asignada a cada ejemplo y la clase real y se obtendrán unas precisiones.

El conjunto de entrenamiento ha de contener más ejemplos que el conjunto de test debido a que cuanto más ejemplos se ofrezcan al modelo, más probable es que aprenda correctamente. Además, para probar cómo de bueno es un modelo, no son necesarios un alto número de ejemplos.

Es importante que a la hora de evaluar el modelo se utilicen datos que no han sido utilizados para entrenar el modelo, ya que esos ejemplos siempre los acertarían. Debido a esto, es necesario tener estas dos divisiones.

Validación cruzada

La validación cruzada es una técnica que se utiliza a la hora de entrenar y probar modelos de aprendizaje. Se basa en dividir el conjunto de datos en un número de partes y utilizar cada una de las partes como conjunto de test y el resto para entrenar el modelo, tal y como se aprecia en la figura 3.4. Cada una de las partes será utilizada como conjunto de test de forma iterativa.

Con esto se consigue que la selección de los conjuntos de entrenamiento y test no perjudique al resultado del modelo y se puedan probar más posibilidades de división de los datos.

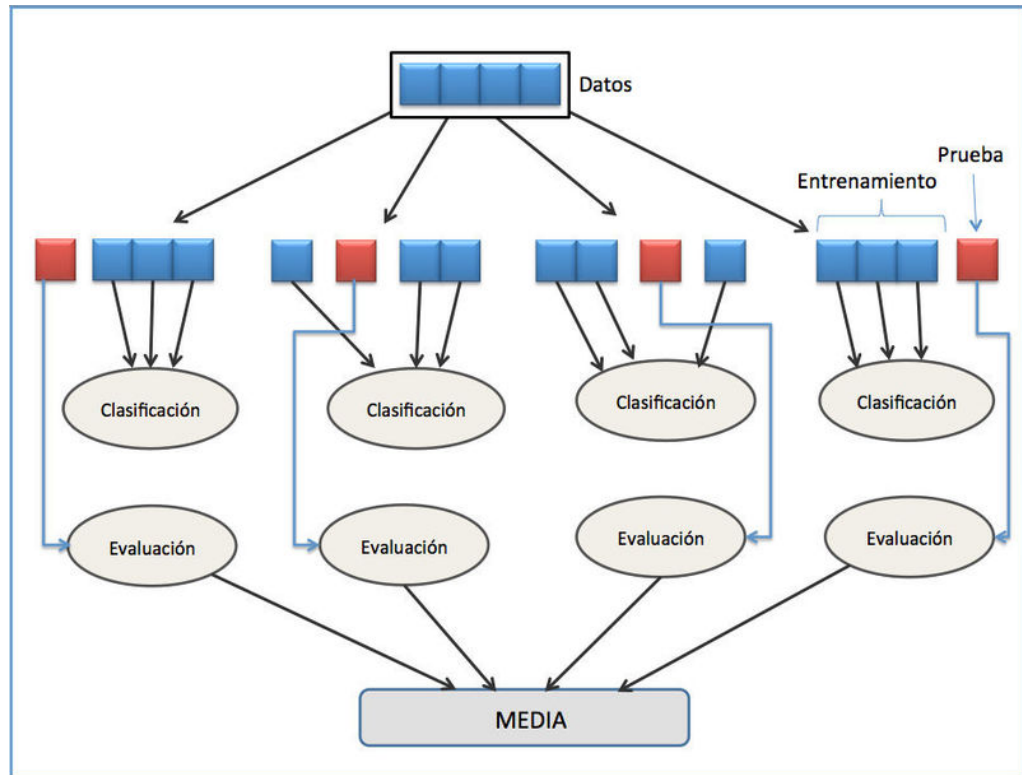


Figura 3.4: Validación cruzada dividiendo el conjunto de ejemplos en 4 partes. [8]

Modelos de clasificación

Una de las formas más sencillas de encontrar patrones en los datos es utilizando modelos de aprendizaje. Hay varios modelos, y cada uno utiliza una forma de clasificar diferente. Los modelos empleados en este TFG son:

- **Árboles de decisión:** se trata de construir un árbol formado por nodos con condiciones y hojas con clases, para que los datos sean clasificados dependiendo de si cumplen una condición de un nodo o no.
- **Random Forest:** se trata de clasificar los ejemplos utilizando varios árboles de decisión. Estos árboles se construyen utilizando un subconjunto del conjunto total de datos de entrenamiento. Cada árbol predirá una clase, y la más frecuente será la que se le asigne al atributo.

- **k-Nearest Neighbors:** se trata de obtener la clase de los vecinos más cercanos al ejemplo que se trata de clasificar. En este clasificador, no hay un paso previo de entrenamiento, sino que los datos de entrenamiento serán los que contengan los k vecinos más cercanos.
- **Naive Bayes:** se trata de calcular la frecuencia de aparición de los valores de cada característica para poder realizar una clasificación. Esto haría que un ejemplo con ciertos valores se le asigne una clase debido a la probabilidad de aparición de sus valores.
- **Naive Bayes Gaussiano:** es una variante del clasificador Naive Bayes y se trata de utilizar las probabilidades de que aparezcan los valores de, pero acorde con una distribución normal.
- **SVM:** se trata de conseguir un hiperplano que separe los ejemplos que compartan la misma clase del resto. A la hora de clasificar un ejemplo, dependiendo de dónde se encuentre, se le asignará una clase u otra.

3.4. Evaluación de los resultados

A la hora de evaluar los resultados, es importante realizar un estudio de los datos obtenidos para poder valorar correctamente los resultados.

Predicciones

Cuando se utiliza un clasificador, se realizan varias predicciones con el conjunto de test. En esta ocasión, hay dos clases posibles: sin Parkinson (0) o con Parkinson (1), por lo que pueden ocurrir cuatro posibilidades:

- Verdadero positivo o *true positive*: ocurre cuando una clase se predice correctamente y además es positiva. En este caso, sería que el clasificador ha predicho un 1 (positivo) y ha acertado. Suele indicarse como TP.
- Verdadero negativo o *true negative*: ocurre cuando una clase se predice correctamente y además es negativa. En este caso, sería que el clasificador ha predicho un 0 (negativo) y ha acertado. Suele indicarse como TN.
- Falso positivo o *false positive*: ocurre cuando una clase no se predice correctamente y además es positiva. En este caso, sería que el clasificador ha predicho un 1 (positivo) y ha fallado. Suele indicarse como FP.

- Falso negativo o *false negative*: ocurre cuando una clase no se predice correctamente y además es negativa. En este caso, sería que el clasificador ha predicho un 0 (negativo) y ha fallado. Suele indicarse como FN.

Medidas

Las medidas son formas de representar los resultados para obtener diferentes puntos de vista a la hora de evaluar los resultados. Las medidas utilizadas en este TFG son:

- *accuracy*: con esta medida se podrá obtener la precisión que ha tenido el clasificador. Esto es, el porcentaje de aciertos que ha habido. La fórmula que se utiliza es la siguiente:

$$accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.2)$$

- *Matthews correlation coefficient*: esta medida es utilizada para conocer la calidad de una clasificación binaria. La fórmula para obtener esta medida es la siguiente:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP) \times (TP + FN) \times (TN + FP) \times (TN + FN)}} \quad (3.3)$$

- *f1*: esta medida es utilizada para recoger las medidas de *precision* y *recall* en una sola medida. La medida *precision* sirve para conocer los aciertos que ha habido en una clase concreta y la medida *recall* sirve para conocer cuántos ejemplos han sido clasificados como una clase concreta. Estas fórmulas son las siguientes:

$$precision = \frac{TP}{TP + FP} \quad recall = \frac{TP}{TP + FN} \quad (3.4)$$

Y la fórmula para obtener la medida f1 es la siguiente:

$$f1 = 2 \times \frac{precision \times recall}{precision + recall} \quad (3.5)$$

- *roc_auc*: esta medida es el área bajo la curva ROC y representa cómo de bueno es un modelo a la hora de diferenciar una clase de otra. Dado que esta métrica es más complicada que las anteriores, más abajo se explica de forma más detallada.

- *g_mean*: esta medida es la media geométrica de la sensibilidad y la especificidad y trata de mostrar la precisión de las clases manteniendo las precisiones de forma equilibrada. Las fórmulas de sensibilidad y especificidad, se pueden ver más abajo. La fórmula para obtener esta medida es la siguiente:

$$g_mean = \sqrt{sensibilidad \times especificidad} \quad (3.6)$$

Curva ROC

La curva ROC [13] (*Receiver Operating Characteristic*) es una representación gráfica utilizada para conocer la proporción de positivos bien clasificados y los positivos mal clasificados.

La curva ROC representada gráficamente tiene como eje x la 1-especificidad y como eje y la sensibilidad. La especificidad corresponde a los ejemplos negativos bien clasificados, o lo que es lo mismo, 1 menos los ejemplos positivos mal clasificados; y la sensibilidad corresponde a los ejemplos positivos bien clasificados. Sus correspondientes fórmulas son las siguientes:

$$especificidad = \frac{TN}{FP + TN} \quad sensibilidad = \frac{TP}{TP + FN} \quad (3.7)$$

Para dibujar la curva ROC habría que recoger varios resultados de un modelo y unir esos puntos para formar la curva, de forma que quede de forma similar que en la figura 3.5, en donde se visualizan tres tipos de curvas ROC que representan clasificaciones de mejor a peor.

Área bajo la curva ROC

El área bajo la curva ROC (*Area Under the ROC Curve*) es la medida con la que conocer cómo de bien un modelo diferencia una clase de otra.

Este área no es más que el cálculo de todo el área que hay debajo de la curva ROC. Los valores obtenidos estarán en el intervalo $[0,1]$. Los valores comprendidos entre 0 y 0.5 indican que el modelo confunde una clase con otra en su mayor parte, mientras que los valores comprendidos entre 0.5 y 1 indican que el modelo predice correctamente la mayoría de ejemplos, siendo el valor 1 la perfección. En la figura 3.5 se aprecian tres valores AUC para cada curva, mostrando que la primera trata de un clasificador perfecto mientras que la última muestra un clasificador mucho peor.




Figura 3.5: Tres tipos de curvas ROC [13].

Técnicas y herramientas

4.1. Herramientas de desarrollo

Anaconda

Anaconda es una distribución libre utilizada para los lenguajes de programación Python y R con el objetivo de realizar aprendizaje automático y ciencia de datos. Entre sus paquetes se encuentra Jupyter Notebook.

Jupyter Notebook

Jupyter Notebook es un entorno de programación para Python basado en la web. Se pueden crear varios notebooks con celdas de código o texto para conseguir una estructura limpia y ordenada. Además, estos notebooks pueden ser usados para otros lenguajes de programación como Julia o R.

4.2. Bibliotecas

OpenCV

Es una biblioteca de Python utilizada para visión artificial y es considerada la más popular. Tiene diversos usos, entre ellos destacan el reconocimiento de objetos y la detección de movimiento. [9]

Numpy

Es una biblioteca de Python utilizada para realizar operaciones matemáticas. También se usa para crear vectores y matrices grandes multidimensionales. [15]

Pandas

Es una biblioteca de Python utilizada para el análisis de datos. Mediante *dataframes* se pueden recoger datos de hojas de cálculo o bases de datos, almacenarlos para ser tratados en el código y después guardarlos de nuevo. [16]

Mediapipe

Es una biblioteca de Python utilizada para visión artificial. Una de las funcionalidades que tiene es la de reconocer y enumerar con puntos una mano.

- *solutions.hands*: este paquete realiza el reconocimiento de la mano para asignar unos puntos. Hay 21 puntos repartidos por toda la mano, los más interesantes para este proyecto son el 4 (dedo pulgar) y el 8 (dedo índice).
- *solutions.drawing_utils*: este paquete es el que se encarga de dibujar los puntos y las conexiones entre ellos sobre la mano.

SciPy

Es una biblioteca de Python utilizada para realizar tareas de ciencia e ingeniería como optimización, álgebra lineal, interpolación o procesamiento de señales. [10]

- *signal*: es el módulo que sirve para realizar procesados de señales como convolución o filtrado, entre otros. [6]

Aspectos relevantes del desarrollo del proyecto

En este apartado, se detallan los aspectos más relevantes que han ocurrido durante el desarrollo del proyecto, así como la manera en la que el proyecto ha sido realizado para cumplir los objetivos propuestos.

5.1. Limpieza de datos

Como ya se ha explicado, los datos obtenidos pueden contener ruido que perjudique la tarea que se quiere realizar, en este caso, la clasificación. Por esta razón, es necesario corregirlos de alguna manera.

Filtro de Savitzky-Golay

En el apartado de conceptos teóricos, ya se mencionó el filtro de Savitzky-Golay, con el que se podían mejorar las gráficas representando los resultados obtenidos.

Estos resultados contienen ruido tanto por el propio pulso de la mano como por la biblioteca que detecta la mano, por lo que su representación en ocasiones muestra demasiados máximos o mínimos parecidos, confundiendo los valores reales.

Distancias

Las distancias ya obtenidas no muestran la distancia real, por lo que es necesario realizar un paso previo antes de calcular el resto de características que dependen de la distancia.

Dado que la pinza cerrada es el momento en el que menos distancia hay, lo lógico sería pensar que esta distancia es 0, sin embargo, esto no ocurre debido a la localización de los puntos de los dedos. Estos puntos no están justo en la yema de los dedos, donde la pinza se cierra, sino que están en el centro del dedo, por lo que la distancia entre esos puntos nunca será 0, aunque sí muy próxima, es decir, las distancias mínimas nunca serán 0. Al igual que sucede con las distancias mínimas, también las distancias máximas se ven afectadas, y en general, todas las distancias. Por esta razón, se realizan nuevamente las restas de los máximos y mínimos de las distancias anteriormente calculadas para que los nuevos mínimos alcancen valores mucho más cercanos al 0.

Para comprender esto mejor, se va a suponer que una distancia mínima entre los dos dedos es de 0,051 y una distancia máxima es de 0,376. Al igual que el 0,051 no es el mínimo real, pues lo lógico sería que fuese 0, la verdadera amplitud máxima tampoco sería real, pues debería contar desde el 0. Para obtener la distancia real habría que obtener la diferencia entre el máximo y el mínimo, para conocer la distancia que les separa, es decir, la amplitud de la pinza, que sería 0,325.

Realmente, todos los puntos no están recogiendo valores reales, sin embargo, dado que sólo interesa recoger la distancia máxima, únicamente se realiza la diferencia entre máximos y mínimos.

5.2. Obtención de características

En este punto se trata de buscar otros datos que caractericen a los vídeos con el fin de poder realizar una clasificación. Habrá datos calculados y datos que ya vienen dados.

Amplitud

Esta característica es la más evidente ya que, generalmente, la gente con Parkinson ven dificultad a la hora de abrir y cerrar la mano hasta su punto máximo.

Para su extracción, en primer lugar, se han recogido los máximos y mínimos de la gráfica de los 5 primeros movimientos y de los 5 últimos. Después, estos datos se normalizan para que no afecte la distancia de la mano a la cámara. Esta normalización se obtiene de la siguiente fórmula:

$$X_{normalizada} = \frac{X_{actual} - X_{mínima}}{X_{máxima} - X_{mínima}} \quad (5.8)$$

Para la extracción de las distancias, tanto la original como la normalizada, tan solo hay que restar el mínimo con el máximo correspondiente.

Tiempo

Otra de las características que podrían afectar a una persona que tiene Parkinson es cuánto tardaría en realizar el movimiento de pinza, ya que, en un principio, aquellos que padezcan la enfermedad tardarán más.

Para ello, se ha realizado la diferencia entre un máximo y el mínimo correspondiente, pero en este caso, para obtener el número de fotogramas que hay entre ambos puntos, con el fin de utilizar como unidad temporal el número de fotogramas, ya que, a más lentitud, más fotogramas habrá de diferencia y viceversa.

Sin embargo, esta medida resulta no ser suficiente porque no se tiene en cuenta cuánto se ha abierto la pinza, es decir, alguien que abra la pinza lentamente y hasta la mitad tardará el mismo tiempo que alguien que la abra más rápido y hasta el máximo.

Velocidad

Para solucionar el problema anterior, se puede utilizar la velocidad. Esto es, calcular la distancia recorrida por unidad de tiempo, por lo que dependiendo de cuánto se recorra y en cuánto tiempo una persona tendrá más velocidad o no.

En una primera instancia, una persona que padece Parkinson, dada su reducida movilidad, pese a abrir la pinza hasta su punto máximo, lo más seguro es que lo hiciera de forma más lenta que otra persona sin Parkinson.

Esta velocidad se calcula realizando la división de la diferencia normalizada entre un máximo y un mínimo (*i. e.* la amplitud ya calculada), entre el tiempo que les separa a ambos puntos (*i. e.* el tiempo ya calculado).

Mano derecha o izquierda

Como añadido, también se ha tenido en cuenta si la mano es derecha o izquierda. En un principio, podría resultar interesante conocer cuál es la mano que más dificultades tiene a la hora de realizar el movimiento,

aunque tampoco resulta fundamental para clasificar. Esta característica no es calculada, sino que viene dada con el vídeo.

Sexo

El sexo de la persona podría servir para clasificar las personas con y sin Parkinson. Como se ha mencionado en la introducción de este documento, el Parkinson es más propenso a aparecer en hombres, por lo que, en primera instancia, podría haber más hombres con Parkinson que mujeres, o lo que es lo mismo, más mujeres sin Parkinson que hombres, lo cual podría ayudar a la hora de clasificar. Al igual que con la mano, esta característica no es calculada, sino que viene dada con el vídeo.

Edad

De forma similar a lo que ocurre con el sexo, el Parkinson es más propenso en personas mayores, de 60 años, por lo que la edad también podría resultar interesante a la hora de clasificar.

Sin embargo, hay que tener cuidado con los ejemplos a la hora de entrenar modelos, ya que el sistema podría aprender que todos los menores de, por ejemplo, 30 años nunca tendrán Parkinson, cuando esto no es cierto. Esta característica tampoco es calculada, también viene dada con el vídeo.

Trabajos relacionados

Además de este proyecto, ha habido otros similares en los que se trata de identificar el Parkinson mediante visión artificial con otro tipo de técnicas.

Dada la gravedad de la enfermedad, ha habido varios estudios aplicando diversas formas de detección de Parkinson para facilitar el trabajo de médicos, además de servir a modo de autodiagnóstico.

En este apartado se van a exponer aquellos trabajos que también se dedican a detectar el Parkinson y que están relacionados con este proyecto.

A new computer vision-based approach to aid the diagnosis of Parkinson's disease

Este trabajo [5] consiste en detectar utilizando técnicas de visión artificial si una persona tiene Parkinson o no mediante dibujos de espirales realizados a mano por varias personas.

El primer paso es el de realizar una prueba en la que hay que dibujar las formas tal y como se aprecia en la figura 6.1, tan solo realizando los ejercicios c y d.

Posteriormente, estos ejercicios son digitalizados para realizar la extracción del dibujo realizado, los cuales se enumeran del 1 al 4 para el ejercicio c y del 5 al 8 para el ejercicio d. Dado que cada individuo realiza 8 dibujos, se acaban obteniendo unos datos. La recogida de datos se realizó tanto a pacientes diagnosticados como a control.

A continuación, el proceso se divide en dos pasos: procesado de imágenes y extracción de características.

El primer paso consiste en separar el dibujo de la persona (HT) del dibujo del papel (ET). Se utilizan técnicas de procesamiento como filtrado y morfología matemática.




Figura 6.1: Prueba a papel que realizó una persona con Parkinson en este proyecto (a) y la hoja en blanco de la prueba (b) [5].

A la hora de obtener el dibujo del paciente (HT), en primer lugar se filtran los dibujos para eliminar el ruido, y en el siguiente paso se utiliza una fórmula que actúe como umbral con el fin de obtener una máscara binaria $M_{ET}^i(I)$, tal y como se muestra:

$$M_{ET}^i(I) = \begin{cases} 0 & \text{if } R^i(I) < 100 \wedge G^i(I) < 100 \wedge B^i(I) < 100 \\ 1 & \text{otherwise,} \end{cases} \quad (6.9)$$

$R^i(I)$, $G^i(I)$ y $B^i(I)$ son los valores del espacio de color RGB del píxel i . Una vez obtenida la máscara $M_{ET}^i(I)$, se restan los píxeles de la imagen original, obteniendo únicamente el dibujo del paciente.

Por otro lado, se obtiene el dibujo de la prueba (ET) de una manera similar. Se utilizan filtrados para eliminar el ruido y, a continuación, se calcula

un umbral mediante una fórmula para obtener una máscara $M_{HT}^i(F)$ que en este caso no será binaria, ya que será necesario obtener el color del bolígrafo para poder separarlo y extraer el dibujo del fondo tal y como se muestra:

$$M_{HT}^i(F) = \begin{cases} 255 & \text{if } |R^i(F) - G^i(F)| < 40 \wedge |R^i(F) - B^i(F)| < 40 \wedge \\ & \wedge |G^i - B^i| < 40 \\ F^i & \text{otherwise,} \end{cases} \quad (6.10)$$

F^i es la saturación de color del píxel i . Al igual que sucedía en el proceso anterior, cuando se obtiene la máscara $M_{HT}^i(F)$, se restan los píxeles de la imagen original, obteniendo únicamente el dibujo de la prueba.

Finalmente, se obtienen dos imágenes en cada dibujo: el dibujo del paciente y el dibujo de la prueba, como se aprecia en la figura 6.2.

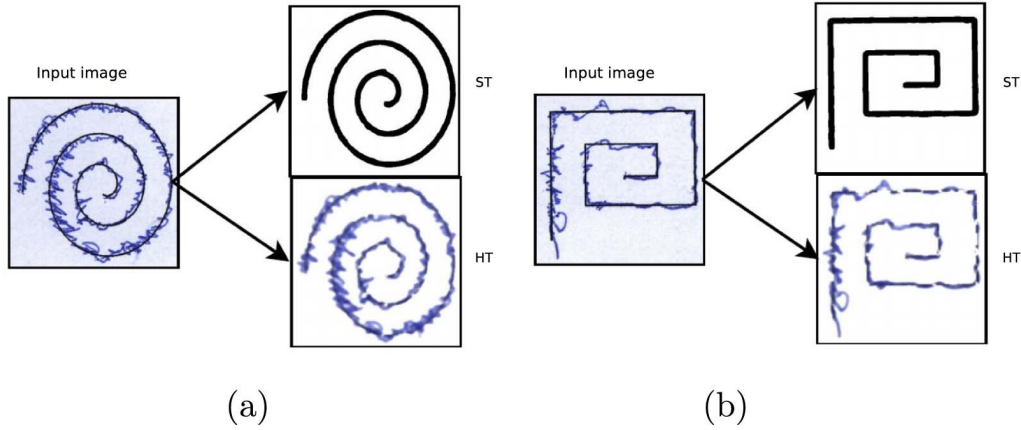


Figura 6.2: Resultado obtenido en cada dibujo del ejercicio c (a) y del ejercicio d (b) [5].

El segundo paso del proceso consiste en extraer características de los dibujos. Para ello se comparan las dos imágenes obtenidas en el primer paso para evaluar cómo de diferentes son.

Para facilitar el proceso, se utiliza el algoritmo de adelgazamiento Zhang-Suen [19], que resumidamente se encarga de hacer que las trazas de los dibujos aparezcan de forma más fina. Además, se corrigen algunas imperfecciones en las imágenes, como líneas discontinuas. Después, se enumeran algunos puntos en las imágenes y se compara la posición entre dos puntos equivalentes para conocer la desviación del dibujo del paciente con respecto

al dibujo de la prueba, obteniendo varios datos con las características de los dibujos. También se obtienen datos obteniendo la distancia entre algunos puntos aleatorios de ambas espirales al centro, ya que la desviación del dibujo del paciente afecta también en su enfermedad de Parkinson. Finalmente, se entrenan los modelos para detectar el Parkinson con todos los datos obtenidos en el paso anterior.

El experimento que se llevó a cabo albergaba dos grupos de personas: uno con gente sin Parkinson y otro con gente con Parkinson. Además, se mezcló en ambos grupos los dos sexos y algún zurdo, frente a una mayoría diestra.

Proposing a Three-Stage Model to Quantify Bradykinesia on a Symptom Severity Level Using Deep Learning

Este proyecto [2] es similar al que se trata en este TFG, ya que también se basa en recoger datos procesando la mano haciendo un movimiento de pinza.

Para ello, se procesan varios vídeos con la mano, tanto izquierda como derecha, habiendo además varios de control. El movimiento realizado debe ser lo más rápido y amplio posible durante 10 segundos.

El preprocesado se realiza utilizando VLC Player para obtener fotogramas de los vídeos. Con Python, y más concretamente, una biblioteca llamada Labellmg se anotan de forma gráfica objetos detectados en la imagen, como se puede observar en la figura 6.3.

Eso servirá para recoger las coordenadas de los dedos índice y pulgar y anotarlos en un fichero de texto de la manera:

```
< object - class >< x_center >< y_center >< width >< height >
```

Utilizando la herramienta YOLO, se consigue que los vídeos sean procesados en tiempo real, y así, se obtiene más velocidad en el preprocesado.

Cada recuadro muestra el ID de la clase y la confianza de detección tal y como se ve en la figura 6.4. El movimiento se conoce comparando las coordenadas del recuadro con las coordenadas del recuadro que tenía el fotograma anterior, lo cual se almacena para cada fotograma junto al momento en el que se calcula.

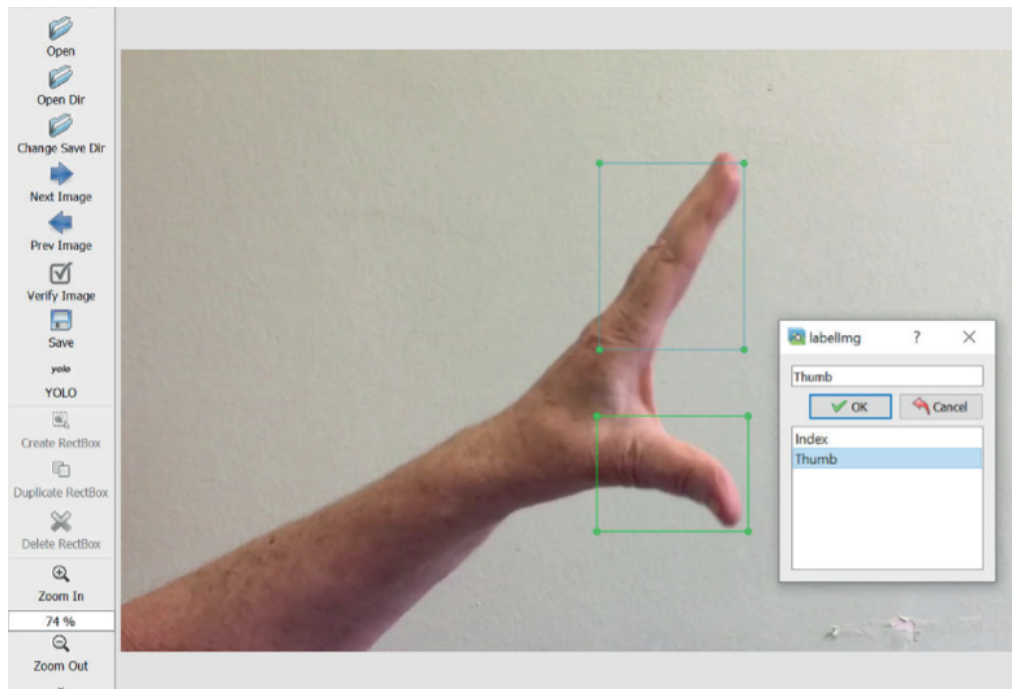


Figura 6.3: Mano con los dedos índice y pulgar etiquetados [2].

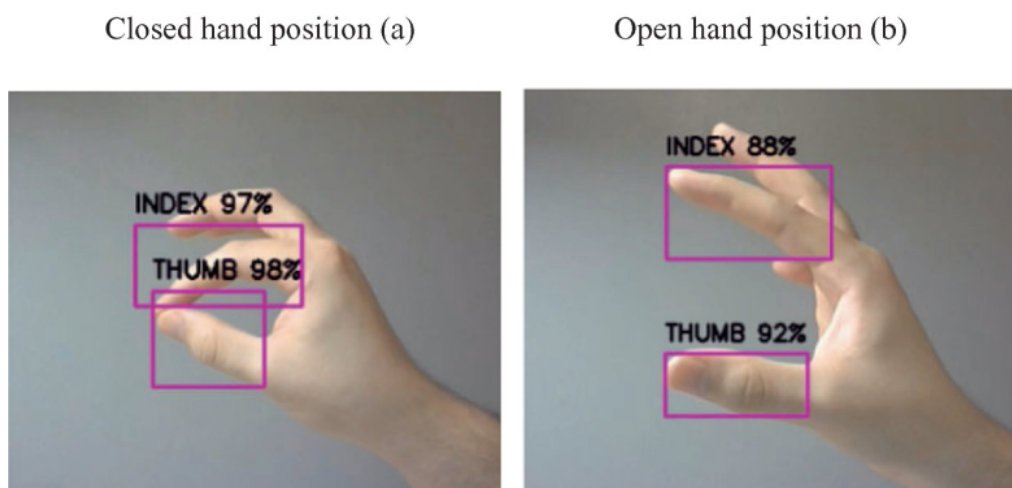


Figura 6.4: Detección realizada con un ajuste ideal [2].

En caso de haber ruido de fondo y/o una orientación de la mano diferente, podría afectar a la confianza de detección, empeorando los resultados obtenidos.

Estos datos obtenidos se utilizan para realizar cálculos con los que sacar conclusiones. Entre los cálculos se encuentran:

- Separación: es el desplazamiento entre dos recuadros.
- Tiempo: se obtiene extrayendo el fotograma actual y restándole el anterior dividido entre los fotogramas capturados por segundo.
- Velocidad: se calcula con la diferencia de separación entre dos fotogramas contiguos dividido entre el tiempo.
- Ritmo: es el producto entre la diferencia de separación de dos fotogramas contiguos y su respectiva velocidad.

Finalmente, los datos se representan en gráficas observar las diferencias de las personas que padecen Parkinson de las que no y con ello alcanzar conclusiones.

The discerning eye of computer vision: Can it measure Parkinson's finger tap bradykinesia?

En este proyecto [18], se ha querido conocer si es posible medir el Parkinson abriendo y cerrando los dedos en forma de pinza, de forma similar a como se hace en el trabajo que representa este documento.

Las mediciones están dentro de la escala MBRS (*Modified Bradykinesia Rating Scale*), que evalúa la velocidad, la amplitud y el ritmo de los movimientos y de la escala MDS-UPDRS [1] (*Movement Disorder Society revision of the Unified Parkinson's Disease Rating Scale*), que se encarga de evaluar aspectos que tiene el Parkinson con respecto a experiencias motoras y no motoras del día a día.

Como herramienta, se utilizó DeepLabCut, que es una herramienta muy similar a la biblioteca Mediapipe de Python que ya se ha explicado en este documento, en la que cualquier parte del cuerpo es marcada con unos puntos para obtener datos acerca de cómo se está moviendo. Sin embargo, para este proyecto sólo se utilizó la herramienta para las manos.

Los puntos de la mano, se utilizaron para conocer el movimiento de los dedos al realizar el movimiento de pinza, creando coordenadas de los dedos

para cada vídeo. Estas coordenadas son las que se utilizaron para obtener la distancia entre los dedos. Además, al igual que en el proyecto que se presenta en el documento, en este también se utilizó el filtrado Savitzky-Golay para eliminar algunos errores que pudiera ocasionar la herramienta.

Los datos que se extrajeron sirvieron para obtener la amplitud, la velocidad y el ritmo del movimiento. Los datos se representaron en forma de gráfica, tal como se aprecia en la figura 6.5. Para la amplitud se recogió la propia amplitud de la onda, para la velocidad se recogió el ratio medio de cambio de los puntos y para el ritmo se utilizó la transformación rápida de Fourier para encontrar la distribución de las frecuencias dentro de cada apertura y cierre de la pinza, donde cuanto más irregular sea el ritmo más ancha será la gráfica y el pico de frecuencia dominante se verá más reducido.




Figura 6.5: Gráficas donde se visualiza la obtención de la velocidad y de la amplitud (arriba) y la obtención del ritmo (abajo) [1].

Finalmente, se analizaron los datos y se obtuvieron conclusiones positivas ya que las diferencias de una persona que padece Parkinson de otra que no son notorias en este tipo de movimientos.

El experimento de este proyecto se realizó con 138 manos, tanto derecha como izquierda, de los cuales 39 tenían Parkinson y 30 no.

A computer vision framework for finger-tapping evaluation in Parkinson's disease

Este proyecto [3] trata de identificar el Parkinson mediante el movimiento de la pinza, pero añadiendo además un reconocimiento facial, con el cual mejorar la obtención de los datos.

Para ello, se siguió el diagrama que se observa en la figura 6.6 con los siguientes pasos:

1. Detectar la cara de la persona mediante un rectángulo y las dos regiones donde está cada mano.
2. Recoger las coordenadas del movimiento de las manos mediante el dedo índice.
3. Normalizar las coordenadas respecto al rectángulo que recuadra la cara de la persona.
4. Extraer las características de cada apertura y cierre de la pinza.
5. Realizar una clasificación utilizando una máquina de soporte vectorial (SVM) para clasificar los niveles de la enfermedad.

El paso de la detección de la cara está basado en que el tamaño de la mano de una persona adulta es muy parecido a la altura de su cara, por lo que se puede realizar una normalización de los datos obtenidos de la mano con respecto a la cara, la cual se realiza en el tercer paso, para así tener en cuenta la distancia a la que está la cámara y que no afecte al resultado. Por otro lado, se detectan a la vez las manos para poder procesarlas en los pasos posteriores. Para esta detección, se utilizó la biblioteca OpenCV.

Para el siguiente paso, el de la detección del movimiento de los dedos, se realiza un análisis de la diferencia entre los cuatro fotogramas anteriores y los 4 posteriores para conocer el movimiento de las manos, ambas de forma separada, tal y como se aprecia en la figura 6.7. Para que exista movimiento,




Figura 6.6: Pasos que se siguieron para la realización de este proyecto [3].

se considera que tiene que haber una diferencia absoluta de 40 píxeles o más, ya que menos representa movimiento insignificante.




Figura 6.7: Detección de la silueta de cada mano (a), orientación del movimiento (b), posiciones de los dedos índice (c) y la imagen actual (d) [3].

Una vez obtenidos las coordenadas del movimiento del paso anterior, en el tercer paso, estas se calibran utilizando la cara de la persona, para normalizar los datos y que no varíen de la distancia a la cámara. Para comprobar que el algoritmo de normalización estaba ajustando correctamente los valores, se realizó una comparación del algoritmo con la utilización de marcadores de color rojo puestos en los dedos, dando el resultado que se aprecia en la figura 6.8. Estos marcadores de color rojo, fueron procesados con el espacio HSV, asegurándose además de que no hubiera ningún otro elemento rojo que pudiera interferir.




Figura 6.8: Marcadores rojos puestos en los dedos para detectar la distancia (a) y comparación del algoritmo (azul) y el procesamiento de los marcadores (rojo) para conocer si el algoritmo ajustaba correctamente (b) [3].

En el penúltimo paso, se extraen a partir de las coordenadas normalizadas del apartado anterior características para poder realizar una clasificación. Hubo que tener en cuenta que, generalmente, las mujeres realizan el movimiento de forma más lenta que los hombres, al igual que sucede con la mano dominante y la no dominante, pues la primera es más rápida. Las características más importantes que se extrajeron fueron: velocidad, amplitud, ritmo y comparación entre franjas horarias.

En el último paso, estas características fueron utilizadas para entrenar un clasificador, con el cual sea capaz de clasificar cada persona con el nivel de Parkinson según la escala UPDRS para el *finger-tapping*, que es el tipo de movimiento que se utilizó en el proyecto. Una vez obtenidos el modelo con las predicciones, se analizaron y se concluyó que esta forma de detectar el Parkinson es viable, principalmente porque es más económico que otro tipo de detección, la cual puede necesitar de equipo costoso, y no requiere de una experiencia para poder utilizar el software.

Este experimento se realizó con los pacientes del centro clínico DIREQT (*Duodopa Infusion: Randomized Efficacy and Quality of life Trial*). Había mezcla de sexos y las edades estaban comprendidas entre los 50 y 75 años. Cada grabación se realizó a lo largo del día a diferentes horas con el fin

de poder obtener posibles diferencias dependiendo del momento del día, obteniendo 17 grabaciones de cada paciente.

Tabla de medidas

En esta sección se recoge de manera resumida en una tabla aquellas medidas que han sido utilizadas en los trabajos expuestos anteriormente y en este TFG.

Trabajo	Amplitud	Tiempo	Velocidad	Ritmo	Comparación
R. Pereira et al. [5]					X
R. Jaber et al. [2]	X	X	X	X	
Williams et al. [18]	X		X	X	
Khan et al. [3]	X		X	X	X
Este trabajo	X	X	X		

Tabla 6.1: Tabla que resume las medidas utilizadas para detectar el Parkinson.

Conclusiones y Líneas de trabajo futuras

Bibliografía

- [1] CG Goetz, W Poewe, B Dubois, A Schrag, MB Stern, AE Lang, et al. Mds-unified parkinson’s disease rating scale (mds-updrs). *Available from the International Parkinson and Movement Disorder Society website: <https://www.movementdisorders.org/MDS/MDS-Rating-Scales/MDS-Unified-Parkinsons-Disease-Rating-Scale-MDS-UPDRS.htm>*, 2008.
- [2] R Jaber, Rami Qahwaji, Amr Abdullatif, J Buckley, and R Abd-Alhameed. Proposing a three-stage model to quantify bradykinesia on a symptom severity level using deep learning. In *UK Workshop on Computational Intelligence*, pages 428–438. Springer, 2021.
- [3] Taha Khan, Dag Nyholm, Jerker Westin, and Mark Dougherty. A computer vision framework for finger-tapping evaluation in parkinson’s disease. *Artificial intelligence in medicine*, 60(1):27–40, 2014.
- [4] MediaPipe. Mediapipe hands. <https://google.github.io/mediapipe/solutions/hands>, 2020. [Internet; descargado 10-abril-2022].
- [5] Clayton R Pereira, Danilo R Pereira, Francisco A Silva, João P Mascieiro, Silke AT Weber, Christian Hook, and João P Papa. A new computer vision-based approach to aid the diagnosis of parkinson’s disease. *Computer Methods and Programs in Biomedicine*, 136:79–88, 2016.
- [6] SciPy. scipy.signal. <https://docs.scipy.org/doc/scipy/reference/signal.html>, 2022. [Internet; descargado 07-marzo-2022].

- [7] Wikipedia. Filtro de savitzky-golay — wikipedia, la enciclopedia libre. https://es.wikipedia.org/w/index.php?title=Filtro_de_Savitzky%E2%80%93Golay&oldid=118855937, 2019. [Internet; descargado 10-abril-2022].
- [8] Wikipedia. Validación cruzada — wikipedia, la enciclopedia libre. https://es.wikipedia.org/w/index.php?title=Validaci%C3%B3n_cruzada&oldid=124047241, 2020. [Internet; descargado 16-abril-2022].
- [9] Wikipedia. Opencv — wikipedia, la enciclopedia libre. <https://es.wikipedia.org/w/index.php?title=OpenCV&oldid=138867795>, 2021. [Internet; descargado 07-marzo-2022].
- [10] Wikipedia. Scipy — wikipedia, la enciclopedia libre. <https://es.wikipedia.org/w/index.php?title=SciPy&oldid=137351442>, 2021. [Internet; descargado 07-marzo-2022].
- [11] Wikipedia. Sustancia negra — wikipedia, la enciclopedia libre. https://es.wikipedia.org/w/index.php?title=Sustancia_negra&oldid=137745078, 2021. [Internet; descargado 08-marzo-2022].
- [12] Wikipedia. Tono muscular — wikipedia, la enciclopedia libre. https://es.wikipedia.org/w/index.php?title=Tono_muscular&oldid=135760058, 2021. [Internet; descargado 08-marzo-2022].
- [13] Wikipedia. Curva roc — wikipedia, la enciclopedia libre. https://es.wikipedia.org/w/index.php?title=Curva_ROC&oldid=142674318, 2022. [Internet; descargado 23-abril-2022].
- [14] Wikipedia. Enfermedad de parkinson — wikipedia, la enciclopedia libre. https://es.wikipedia.org/w/index.php?title=Enfermedad_de_Parkinson&oldid=141456130, 2022. [Internet; descargado 08-marzo-2022].
- [15] Wikipedia. Numpy — wikipedia, la enciclopedia libre. <https://es.wikipedia.org/w/index.php?title=NumPy&oldid=141830635>, 2022. [Internet; descargado 07-marzo-2022].
- [16] Wikipedia. Pandas (software) — wikipedia, la enciclopedia libre. [https://es.wikipedia.org/w/index.php?title=Pandas_\(software\)&oldid=141239349](https://es.wikipedia.org/w/index.php?title=Pandas_(software)&oldid=141239349), 2022. [Internet; descargado 07-marzo-2022].

- [17] Wikipedia. Sistema nervioso autónomo — wikipedia, la enciclopedia libre. https://es.wikipedia.org/w/index.php?title=Sistema_nervioso_aut%C3%B3nomo&oldid=142359378, 2022. [Internet; descargado 08-marzo-2022].
- [18] Stefan Williams, Zhibin Zhao, Awais Hafeez, David C Wong, Samuel D Relton, Hui Fang, and Jane E Alty. The discerning eye of computer vision: Can it measure parkinson’s finger tap bradykinesia? *Journal of the Neurological Sciences*, 416:117003, 2020.
- [19] Tongjie Y Zhang and Ching Y. Suen. A fast parallel algorithm for thinning digital patterns. *Communications of the ACM*, 27(3):236–239, 1984.